Fundamentación teórica y técnica del plan experimental del proyecto integrador

Clasificación de cinco flores comunes mediante transferencia desde un modelo fundacional visual

Leonar Socarrás Molina, PhD · John Jairo Serrano Cifuentes, Esp. · Grupo 15

Maestría en Inteligencia Artificial, Universidad de La Sabana

Técnicas Avanzadas de Modelado en IA (MIA 2026-5) · Docente: PhD. Oscar Alberto Rodríguez Meléndez

18 de octubre de 2026

Resumen

Este documento argumenta, con fuentes verificables y con la evidencia del repositorio, cada decisión del plan experimental entregado en la Actividad 1 de la Unidad 4. El proyecto clasifica fotografías de cinco flores ornamentales (margarita, diente de león, rosa, girasol y tulipán) para apoyar bitácoras escolares de observación botánica. Sobre tf_flowers se auditaron 3 670 imágenes, se excluyeron 11 por licencia no verificable o etiqueta contradictoria, y se construyeron 1 531 grupos de fuga que unen fotos del mismo autor, con los mismos píxeles o casi duplicadas. Con ellos se fijó una partición 70/15/15 estratificada por grupos. La escalera de líneas base produjo, en macro-F1 de prueba, 0,079 para la clase mayoritaria, 0,569 para HOG con color y regresión logística, 0,718 ± 0,017 para una CNN pequeña desde cero y 0,987 para una sonda lineal sobre DINOv2 ViT-S/14 congelado. La validación cruzada agrupada y una prueba de robustez con cuatro degradaciones de captura ubican el margen de mejora en la estabilidad entre autores (0,961 ± 0,009 en validación cruzada agrupada) y en el desempeño con

fotos de baja resolución (0,954). El documento cierra con la justificación de la arquitectura candidata (LP-FT y LoRA sobre DINOv2), del diseño experimental de la Actividad 2 y de la matriz de riesgos.

Palabras clave: transferencia de aprendizaje, modelos fundacionales, DINOv2, fuga de información, validación agrupada, calibración, robustez, hoja de datos.

1. Introducción y formulación

Un proyecto de aprendizaje automático empieza con una decisión que necesita evidencia, antes que con la elección de una red. La cartilla de la unidad pide que la formulación declare quién usa el resultado, qué acción apoya, qué datos existen, qué salida se espera y qué error resulta más costoso (Rodríguez Meléndez y Mojica Macías, 2026). En la sesión sincrónica del 13 de octubre el docente insistió en la misma idea con un contraste: justificar un Transformer por ser el modelo más avanzado no constituye un experimento, mientras que preguntar si, bajo el mismo split y el mismo presupuesto, ese modelo reduce un error medido frente a una alternativa concreta sí lo es (Rodríguez Meléndez, 2026).

En este proyecto el usuario es un estudiante o docente de ciencias que fotografía flores en huertas y jardines escolares con un celular o un portátil sin GPU. La decisión que apoya el sistema es aceptar la etiqueta sugerida para la bitácora o, si el sistema se abstiene, repetir la foto y consultar una guía. El error más costoso es una etiqueta equivocada emitida con alta confianza, porque entra al registro como dato válido; le sigue forzar a una de las cinco clases una flor que no pertenece a ninguna. De esta jerarquía de costos se deriva que la calibración y la abstención pesen tanto como el acierto, porque la métrica debe elegirse según el error que más cuesta (Rodríguez Meléndez, 2026).

Conviene separar el problema real del problema medible. El problema real, identificar la flora de un entorno escolar del Caribe colombiano, es abierto y tropical. El problema medible es una clasificación cerrada de cinco clases templadas sobre fotos de Flickr. El plan declara esa brecha desde el inicio como desplazamiento de covariables y de alcance, siguiendo la recomendación de explicitar qué diferencias entre los datos y el uso podrían degradar la generalización (Rodríguez Meléndez, 2026).

2. Marco teórico

2.1 Transferencia de aprendizaje y modelos fundacionales

La transferencia parte de un supuesto empírico: las capas de una red entrenada sobre un corpus amplio aprenden representaciones que sirven para tareas distintas a la original. Yosinski et al. (2014) mostraron que las primeras capas son generales y que la especificidad aumenta con la profundidad, de modo que congelar el tronco y entrenar una cabeza nueva es una estrategia razonable cuando los datos propios son escasos. Los modelos fundacionales llevan esa lógica al extremo. DINOv2 entrena un ViT de unos mil millones de parámetros con autosupervisión sobre LVD-142M, un corpus de 142 millones de imágenes curado automáticamente, y lo destila en modelos más pequeños (Oquab et al., 2024). Sus autores reportan que una sonda lineal sobre el tronco congelado ViT-S/14 alcanza 99,6 % en Oxford Flowers. Ese dato funciona en este proyecto como predicción falsable: si la sonda lineal sobre tf_flowers rinde cerca de ese techo, la pregunta científica deja de ser cuánto mejora la exactitud y pasa a ser en qué condiciones el modelo falla.

La elección entre congelar y ajustar no es neutra. Kumar et al. (2022) demostraron que el ajuste fino completo con una cabeza aleatoria distorsiona las representaciones preentrenadas y puede

rendir peor fuera de distribución que la sonda lineal. Propusieron LP-FT: entrenar primero la sonda y luego ajustar el modelo completo partiendo de ella. En su evaluación, LP-FT supera al ajuste fino directo por cerca de un punto dentro de distribución y diez fuera de ella. Para este plan, cuya debilidad medida es la robustez, el argumento es directo. LoRA ofrece una alternativa más barata: Hu et al. (2022) congelan los pesos y aprenden actualizaciones de bajo rango en las proyecciones de atención, con muchos menos parámetros entrenables y sin latencia adicional tras fusionarlas.

2.2 Fuga de información y validación agrupada

La documentación de scikit-learn define la fuga como el uso de información que no estaría disponible al predecir, y advierte que infla las estimaciones, incluida la validación cruzada (Scikit-learn Developers, s. f.-a). En visión, la forma más frecuente es la repetición de la misma escena, persona o fuente entre entrenamiento y prueba; el escalado previo al split es un caso menos común. El docente lo ilustró con 10 000 personas que aportan 200 fotogramas cada una: si el split se hace por imagen, el modelo aprende la identidad y la validación miente; hay que separar por identidad y solo después mezclar dentro de cada conjunto (Rodríguez Meléndez, 2026). La guía de validación cruzada de scikit-learn formaliza esta regla con GroupKFold y StratifiedGroupKFold, que mantienen cada grupo completo en un solo pliegue y, en el segundo caso, preservan la proporción de clases (Scikit-learn Developers, s. f.-b).

En tf_flowers la entidad equivalente a la persona es el fotógrafo. Un mismo autor de Flickr aporta hasta 63 fotos tomadas con la misma cámara, en el mismo jardín y a veces de la misma planta. Una partición aleatoria permitiría que el modelo reconociera el estilo del autor en lugar de

la flor, que es el caso de varias muestras por entidad para el que la documentación reserva la validación agrupada (Scikit-learn Developers, s. f.-b).

2.3 Métricas, calibración y predicción selectiva

Zinkevich (s. f.) separa el objetivo que se optimiza de la métrica que decide, y recomienda definir la métrica antes de entrenar (Regla 2). La entropía cruzada es la pérdida; la métrica de decisión es el macro-F1, que promedia el F1 de cada clase con igual peso y por eso no se deja dominar por la clase mayoritaria. En multiclase de etiqueta única el micro-F1 coincide con la exactitud, razón por la cual esta solo se reporta como secundaria; el docente fue explícito en que la considera engañosa cuando hay desbalance (Rodríguez Meléndez, 2026).

Una red puede discriminar bien y estar mal calibrada. Guo et al. (2017) definieron el error de calibración esperado (ECE) como la diferencia ponderada entre la confianza media y la exactitud en contenedores de confianza, y mostraron que el escalado de temperatura, un único parámetro ajustado en validación, reduce el ECE sin cambiar la clase predicha. El docente recomendó en la sesión esta calibración post hoc (Rodríguez Meléndez, 2026). La predicción selectiva completa el razonamiento: con un umbral de confianza fijado en validación, el sistema acepta solo las predicciones que superan un nivel de precisión y se abstiene en las demás. Así se convierte el error más costoso de la formulación en una cantidad medible, la cobertura a precisión fija.

2.4 Robustez ante degradaciones de captura

Hendrycks y Dietterich (2019) propusieron evaluar la robustez con familias de corrupciones comunes (desenfoque, ruido, compresión, cambios de brillo) aplicadas a datos de prueba que el modelo nunca vio, y advirtieron que entrenar con las mismas corrupciones que se evalúan sobreestima la robustez real. Este plan adopta ambas reglas: mide la línea base con cuatro

degradaciones típicas de un celular y reserva para la evaluación familias de perturbación distintas de las que se usarán como aumentación.

2.5 Documentación y gestión de riesgos

Gebru et al. (2021) propusieron acompañar cada conjunto de datos con una hoja que responda preguntas sobre motivación, composición, recolección, preprocesamiento, usos, distribución y mantenimiento, y aceptan que un consumidor del conjunto responda "desconocido" cuando la información no existe. Mitchell et al. (2019) hicieron lo análogo para los modelos con las fichas de modelo, que la Actividad 3 exigirá. El marco AI RMF 1.0 organiza la gestión de riesgos en cuatro funciones: gobernar, mapear, medir y gestionar (National Institute of Standards and Technology [NIST], 2023). Su apéndice B señala que los modelos preentrenados aumentan la incertidumbre estadística y dificultan la reproducibilidad, lo que obliga a tratar el modelo fundacional como fuente de riesgo y no solo de desempeño.

3. Método

3.1 Datos y auditoría

El archivo oficial flower_photos.tgz (TensorFlow Team, 2019) se verificó con SHA-256 (4c54ace7911aaffe13a365c34f650e71dd5bf1be0a58b464e5a7183e3e595d9c). La auditoría calcula para cada imagen el MD5 de los bytes y de los píxeles decodificados, un hash perceptual de 64 bits, la saturación media en HSV, brillo, contraste, varianza del laplaciano como indicador de nitidez y la desviación del ruido según Immerkær (1996). El fragmento siguiente muestra el estimador de ruido, que opera con un único núcleo de convolución y por eso escala a miles de imágenes en segundos.

```
# Núcleo de Immerkær (1996): anula estructuras suaves y conserva el ruido
IMMERKAER = np.array([[1, -2, 1], [-2, 4, -2], [1, -2, 1]], dtype=float)


def noise_sigma(gray: np.ndarray) -> float:
    """Desviación del ruido gaussiano estimada sobre la imagen en grises."""
    h, w = gray.shape
    conv = np.abs(convolve(gray, IMMERKAER))
    return float(np.sqrt(np.pi / 2) * conv[1:-1, 1:-1].sum() / (6 * (w - 2) * (h -
2)))
```

Se excluyeron 9 imágenes sin línea de licencia y 2 copias de la misma foto guardadas en las carpetas de rosas y de tulipanes. Las demás anomalías se conservaron como subgrupos de análisis, en respuesta a la pregunta de la hoja de datos sobre errores, ruido y redundancias (Gebru et al., 2021): 88 imágenes casi monocromas (saturación media menor de 0,08), de las cuales 49 son dientes de león, lo que sugiere un posible atajo de color o fondo; 149 oscuras; 32 sobreexpuestas; 21 borrosas; 135 con ruido alto y 397 con el lado menor por debajo de 200 píxeles.

3.2 Grupos de fuga y partición

Un grupo de fuga es una componente conexa del grafo cuyas aristas unen imágenes con el mismo autor, los mismos píxeles o un hash perceptual a seis bits o menos de distancia de Hamming. La distancia entre todos los pares se calcula de forma vectorizada, sin bucles de Python, como se recomendó en la sesión para el cómputo numérico (Rodríguez Meléndez, 2026).

```
def near_duplicate_pairs(bits: np.ndarray, max_bits: int) -> np.ndarray:
    """Pares (i, j), i < j, con distancia de Hamming <= max_bits (vectorizado)."""
    b = bits.astype(np.int16)
    ones = b.sum(1)
```

```
    dist = ones[:, None] + ones[None, :] - 2 * (b @ b.T)   # |a| + |b| - 2|a ∧ b|
    i, j = np.where(np.triu(dist <= max_bits, k=1))
    return np.stack([i, j], 1)
```

Los 1 531 grupos se repartieron con StratifiedGroupKFold (Scikit-learn Developers, s. f.-b) en 20 pliegues con semilla 2026: tres para prueba, tres para validación y catorce para entrenamiento, con 2 564, 548 y 547 imágenes. El contraste con una partición aleatoria estratificada de iguales proporciones cuantifica la fuga evitada: en ella, 74,3 % de las fotos de prueba tendrían un autor presente en entrenamiento y 5 tendrían su casi duplicado allí. Cinco pruebas automáticas comprueban que ningún grupo, autor o par de píxeles idénticos cruce particiones y que las proporciones de clase coincidan; otras tres validan las métricas.

3.3 Escalera de líneas base

Las líneas base siguen la progresión que propone el docente (Rodríguez Meléndez, 2026): una regla heurística, un modelo clásico con rasgos razonables, una arquitectura pequeña y, como cuarto peldaño, la representación fundacional sin ajuste. La regla heurística como primer lanzamiento y el modelo interpretable como punto de partida provienen de Zinkevich (s. f., Reglas 1 y 14). Cada peldaño responde una pregunta. Todas heredan de una clase abstracta que fija el contrato y registra en MLflow los parámetros, el hash de la partición, las métricas y los artefactos.

```
class BaseExperimento(ABC):
    """Contrato: ajustar() devuelve probabilidades de validación y prueba."""


    @abstractmethod
    def ajustar(self) -> tuple[np.ndarray, np.ndarray]:
        """Entrena con train, selecciona con val y devuelve (proba_val,
```

```
proba_test)."""


    def ejecutar(self) -> dict:
        mlflow.set_tracking_uri(self.cfg.get("mlflow_uri", "sqlite:///mlflow.db"))
        mlflow.set_experiment(self.cfg["experimento_mlflow"])
        with mlflow.start_run(run_name=self.cfg["run"]):
            ...  # parámetros, hash de la partición, métricas e IC por autor
```

La herencia se justifica porque existe una relación real de tipo "es un": cada línea base es un experimento con el mismo contrato. El estado del entrenamiento de la CNN (modelo, optimizador, historial y mejor checkpoint) vive en una clase Entrenador, mientras que las métricas sin estado son funciones; ambas decisiones siguen la regla de diseño que el docente expuso en la sesión (Rodríguez Meléndez, 2026). E01 concatena un histograma HSV de 16 × 4 × 4 contenedores con HOG de nueve orientaciones (Dalal y Triggs, 2005) y ajusta una regresión logística con C elegido en validación. E02 es la CNN de la U2A4 (tres convoluciones 3 × 3 de 16, 32 y 64 filtros con max-pooling, densa de 128 y salida de 5; 1 204 005 parámetros) a 96 píxeles, con la aumentación combinada que allí resultó útil, 30 épocas y selección del mejor checkpoint por pérdida de validación (Rodríguez Meléndez, 2026); se entrenó con tres semillas. E03 extrae el token de clase de DINOv2 ViT-S/14 congelado (Oquab et al., 2024) a 224 píxeles y ajusta una regresión logística.

3.4 Incertidumbre y comparación

Los intervalos de confianza del 95 % se obtienen remuestreando autores completos, en lugar de imágenes sueltas, con 2 000 réplicas, porque las fotos de un mismo autor no son independientes. Las comparaciones entre modelos sobre la misma prueba usan la prueba exacta de McNemar, que solo considera los casos donde uno acierta y el otro falla y que Dietterich (1998) recomendó

cuando cada modelo se entrena una sola vez. Como control de fuga en la tubería se reentrena la sonda con etiquetas de entrenamiento permutadas: su desempeño debe caer al nivel del azar, análogo al ejemplo de selección de rasgos con etiquetas aleatorias de Scikit-learn Developers (s. f.-a).

4. Resultados

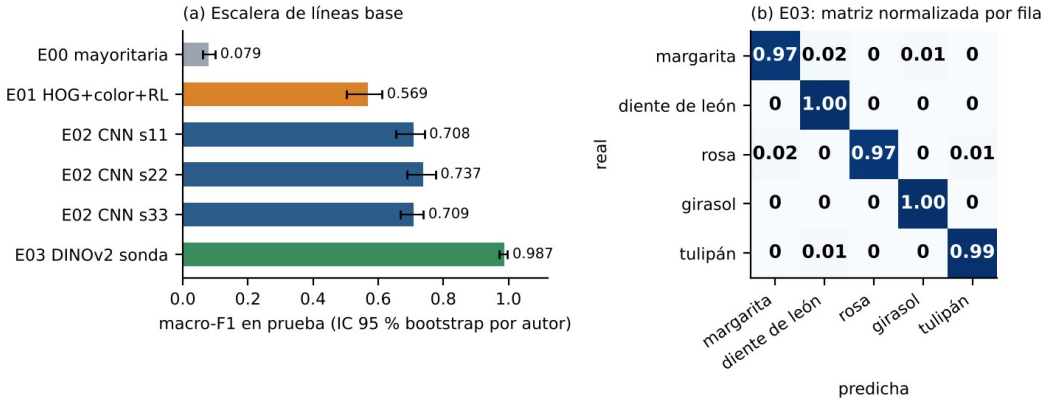
La Tabla 1 resume la escalera de líneas base en la partición de prueba.

Tabla 1. Líneas base en la prueba agrupada (547 imágenes; CPU de 2 hilos).

Run	Modelo	Macro-F1 (IC 95 %)	Exactitud balanceada	ECE	Latencia P95
E00	Clase mayoritaria	0,079 (0,062 a 0,100)	0,200	0,754	despreciable
E01	HOG + HSV + regresión logística	0,569 (0,503 a 0,612)	0,569	0,120	10,1 ms
E02	CNN desde cero, 3 semillas	0,718 ± 0,017	0,721	0,062	3,5 ms
E03	DINOv2 ViT-S/14 congelado + RL	0,987 (0,971 a 0,997)	0,986	0,009	141 ms

El modelo clásico rinde poco (0,569), lo que justifica pasar a redes profundas según el criterio que el docente fijó en la sesión (Rodríguez Meléndez, 2026). La CNN desde cero mejora, pero con un costo de entrenamiento de unos cinco minutos y medio por semilla en CPU (30 épocas), frente a menos de un segundo para ajustar la sonda de E03 una vez extraídos los embeddings, y con una dispersión apreciable entre semillas. La sonda lineal sobre DINOv2 supera a ambas por un margen amplio (McNemar exacto, $p < 10^{-36}$ frente a cada semilla de E02 y $p < 10^{-64}$ frente a E01; Dietterich, 1998) y entrena solo 1 925 parámetros. Con etiquetas permutadas, la misma

sonda cae a un macro-F1 de 0,211 en validación, señal de que la tubería no filtra información. La corrida oficial del repositorio, independiente de la exploración inicial, reprodujo las cifras.



Escalera de líneas base con IC 95 % por autor y matriz de confusión de E03.

E03 comete 7 errores en prueba, tres en margaritas (dos tomadas por diente de león y una por girasol), tres en rosas (dos por margarita y una por tulipán) y un tulipán tomado por diente de león. La validación cruzada agrupada en cinco pliegues sobre entrenamiento y validación (Scikit-learn Developers, s. f.-b) da 0,961 ± 0,009. La prueba (0,987) supera a todos los pliegues y la validación simple marca 0,950: la partición de prueba resultó más fácil que el promedio, un efecto de la varianza entre grupos de autores. Por eso la Actividad 2 seleccionará modelos con la validación cruzada agrupada y reservará la prueba para el reporte final.

Tabla 2. Robustez de la línea base E03 ante degradaciones de captura.

Condición de prueba	Macro-F1 de E03
Limpia	0,987
Desenfoque gaussiano, radio 2	0,977
JPEG, calidad 20	0,988
Subexposición al 50 %	0,987
Resolución reducida a la cuarta parte	0,954

La representación congelada resiste bien tres de las cuatro degradaciones evaluadas con el protocolo de corrupciones comunes (Hendrycks y Dietterich, 2019). La excepción es la baja

resolución, con una caída relativa de 3,3 %, relevante porque 397 fotos del conjunto ya tienen menos de 200 píxeles de lado. Junto con la brecha entre la validación cruzada agrupada y la prueba, esa caída define la mejora que se exigirá a la arquitectura candidata.

5. Discusión

5.1 Qué significa mejorar cuando la línea base ya es alta

El resultado de E03 confirma la predicción derivada de Oquab et al. (2024). Ganar décimas sobre 0,987 no sería informativo, porque el intervalo de confianza ya es estrecho y una diferencia de dos o tres imágenes cae dentro del ruido. Zinkevich (s. f.) recomienda elegir por la utilidad del sistema completo antes que por el poder predictivo aislado (Regla 25), y en la sesión del 13 de octubre el docente pidió comparar los modelos como parte de ese sistema completo (Rodríguez Meléndez, 2026). Por eso las metas de la Actividad 2 se formulan como mejora del macro-F1 medio en validación cruzada agrupada, criterio de no inferioridad en la prueba y mejoras en baja resolución, calibración y cobertura a precisión fija.

5.2 Por qué LP-FT y no ajuste fino directo

Las debilidades medidas de E03 son la variación entre autores no vistos y la baja resolución, ambas formas de desplazamiento de distribución. Kumar et al. (2022) muestran que es justo allí donde el ajuste fino directo deteriora las representaciones y donde LP-FT conserva su ventaja. LoRA (Hu et al., 2022) se incluye como variable científica porque responde otra pregunta del sistema: si se puede adaptar el modelo con menos parámetros entrenables y sin costo de latencia en un portátil escolar.

5.3 Comparación justa

El docente advirtió que fijar el mismo número de épocas para modelos de distinta capacidad no es una comparación justa y propuso igualar el presupuesto de cómputo (Rodríguez Meléndez, 2026); el plan asigna a cada run el mismo presupuesto de 30 minutos de GPU T4: cada tasa de aprendizaje se prueba con una semilla en validación, la ganadora de cada estudio se evalúa en los cinco pliegues de la validación cruzada agrupada y las tres semillas se reservan para la finalista, unas 16 horas de GPU en total. El Tuning Playbook de Google formaliza la distinción entre hiperparámetros científicos (lo que se quiere estudiar), de ajuste (lo que se optimiza para comparar con justicia) y fijos (Google Developers, s. f.). La tabla de experimentos del plan aplica esa clasificación: la estrategia de adaptación es la variable científica, la tasa de aprendizaje y el decaimiento de pesos se ajustan en validación, y la partición, la resolución, el lote, el preprocesamiento y las semillas permanecen fijos.

5.4 Riesgos y límites de validez

Tres límites condicionan cualquier conclusión. El primero es la posible superposición entre el corpus de preentrenamiento de DINOv2 y las fotos de Flickr; no se puede descartar sin acceso a LVD-142M, y por eso las cifras limpias se leen como cota optimista (Oquab et al., 2024). El segundo es la brecha entre la flora templada del conjunto y la flora tropical del contexto escolar; solo un conjunto de campo propio permitiría medirla. El tercero es la ausencia de una clase "otra flor": el sistema siempre elige entre cinco, y la abstención calibrada es la única defensa planificada. La matriz de riesgos del plan asigna a cada uno una mitigación y un responsable, en línea con las funciones de medir y gestionar del marco de NIST (2023).

6. Conclusiones

El plan cumple los siete criterios de la actividad con evidencia ejecutable y documentada según las hojas de datos (Gebru et al., 2021) y el marco de riesgos de NIST (2023). El problema, el usuario y el error más costoso están delimitados. El conjunto de datos tiene hoja de datos, licencia verificada y limitaciones explícitas. La partición agrupada por autor elimina una contaminación que la partición aleatoria habría introducido en tres de cada cuatro fotos de prueba. Las métricas se eligieron por el costo de los errores. La línea base es reproducible y está registrada en MLflow. Los riesgos están mapeados y la arquitectura candidata responde a la debilidad que la propia línea base reveló. La contribución metodológica principal es haber mostrado, con validación cruzada agrupada, que una sola partición de prueba sobrestimaba el desempeño, y haber trasladado la pregunta de cuánto acierta el modelo a cuándo deja de acertar, que es lo que importa a quien usará la herramienta en un aula.

Referencias

Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. En *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)* (Vol. 1, pp. 886-893). IEEE. https://doi.org/10.1109/CVPR.2005.177

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation, 10*(7), 1895-1923. https://doi.org/10.1162/089976698300017197

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86-92. https://doi.org/10.1145/3458723

Google Developers. (s. f.). *A scientific approach to improving model performance*. En *Deep learning tuning playbook*. https://developers.google.com/machine-learning/guides/deep-learning-tuning-playbook/scientific

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. En *Proceedings of the 34th International Conference on Machine Learning* (Vol. 70, pp. 1321-1330). PMLR.

Hendrycks, D., & Dietterich, T. (2019). Benchmarking neural network robustness to common corruptions and perturbations. En *International Conference on Learning Representations*. https://arxiv.org/abs/1903.12261

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. En *International Conference on Learning Representations*. https://arxiv.org/abs/2106.09685

Immerkær, J. (1996). Fast noise variance estimation. *Computer Vision and Image Understanding, 64*(2), 300-302. https://doi.org/10.1006/cviu.1996.0060

Kumar, A., Raghunathan, A., Jones, R., Ma, T., & Liang, P. (2022). Fine-tuning can distort pretrained features and underperform out-of-distribution. En *International Conference on Learning Representations*. https://arxiv.org/abs/2202.10054

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220-229). ACM. https://doi.org/10.1145/3287560.3287596

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)* (NIST AI 100-1). U.S. Department of Commerce. https://doi.org/10.6028/NIST.AI.100-1

Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., . . . Bojanowski, P. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. https://arxiv.org/abs/2304.07193

Rodríguez Meléndez, O. A. (2026). *Diseño experimental e ingeniería de proyectos de ML* [Diapositivas y sesión sincrónica del 13 de octubre]. Técnicas Avanzadas de Modelado en IA, Universidad de La Sabana.

Rodríguez Meléndez, O. A., & Mojica Macías, J. P. (2026). *Proyecto integrador de modelado avanzado en ML y DL* [Cartilla interactiva de la Unidad 4]. Técnicas Avanzadas de Modelado en IA, Universidad de La Sabana.

Scikit-learn Developers. (s. f.-a). *Common pitfalls and recommended practices*. https://scikit-learn.org/stable/common_pitfalls.html

Scikit-learn Developers. (s. f.-b). *Cross-validation: Evaluating estimator performance*. https://scikit-learn.org/stable/modules/cross_validation.html

TensorFlow Team. (2019). *Flowers* [Conjunto de datos]. TensorFlow Datasets. https://www.tensorflow.org/datasets/catalog/tf_flowers

Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? *Advances in Neural Information Processing Systems, 27*, 3320-3328.

Zinkevich, M. (s. f.). *Rules of machine learning: Best practices for ML engineering*. Google for Developers. https://developers.google.com/machine-learning/guides/rules-of-ml

Declaración de uso de IA

El equipo usó Claude (Anthropic) como asistente para programar, revisar fuentes y redactar borradores. Las decisiones, la verificación de cada cifra contra el repositorio y la versión final son responsabilidad de los autores.