Plan experimental del proyecto integrador: clasificación de cinco flores comunes mediante transferencia desde un modelo fundacional visual

Leonar Socarrás Molina, PhD (leonarsomo@unisabana.edu.co) · John Jairo Serrano Cifuentes, Esp. (johnseci@unisabana.edu.co) · Grupo 15
Maestría en Inteligencia Artificial, Universidad de La Sabana · Técnicas Avanzadas de Modelado en IA (MIA 2026-5) · Unidad 4, Actividad 1
Docente: PhD. Oscar Alberto Rodríguez Meléndez · 18 de octubre de 2026 · Repositorio: https://github.com/leonarsomo/flores-proyecto-integrador

Resumen. El plan delimita un clasificador de fotografías de cinco flores ornamentales (margarita, diente de león, rosa, girasol y tulipán) para apoyar registros escolares de observación botánica. Sobre tf_flowers (3 670 fotos de Flickr, CC-BY 2.0) se auditó la calidad, se construyeron 1 531 grupos de fuga por autor y casi duplicados y se fijó una partición 70/15/15 estratificada por grupos. La escalera de líneas base va de la clase mayoritaria (macro-F1 = 0,079) a descriptores HOG con color (0,569), una CNN desde cero (0,718 ± 0,017) y una sonda lineal sobre DINOv2 congelado (0,987). La validación cruzada agrupada por autor revela que la prueba es más fácil que cualquier pliegue (0,961 ± 0,009), y la reducción de resolución es la degradación que más afecta (0,954). Por eso la mejora exigible a la arquitectura candidata se mide en validación cruzada agrupada, en baja resolución y en abstención calibrada.

1. Problema, usuario y alcance

El **problema real** es apoyar a estudiantes y docentes que fotografían flores en huertas y jardines escolares, y que necesitan una sugerencia confiable para su bitácora de observación. El **problema medible** es más estrecho: asignar una de cinco clases a una fotografía RGB de aficionado y declarar cuándo no hay confianza suficiente. La Tabla 1 resume la formulación pedida en la cartilla de la unidad (Rodríguez Meléndez y Mojica Macías, 2026).

Tabla 1
Formulación del problema y delimitación del alcance

Pregunta	Respuesta del proyecto
¿Quién usa el resultado?	Estudiantes de secundaria y docentes de ciencias que registran observaciones de flores con un celular o un portátil escolar, sin GPU.
¿Qué decisión apoya?	Aceptar la etiqueta sugerida para la bitácora, o repetir la foto y consultar una guía cuando el sistema se abstiene.
¿Qué datos existen?	tf_flowers: 3 670 fotos etiquetadas por carpeta, cinco clases, licencia CC-BY por imagen y atribución por autor.
Variable objetivo y predictores	Especie de la flor: variable categórica nominal de cinco clases (margarita, diente de león, rosa, girasol, tulipán), tomada de la carpeta de origen (TensorFlow Team, 2019). Predictores: los píxeles RGB de la foto, sin metadatos.
¿Qué salida se espera?	Clase, probabilidad calibrada y opción de abstención por debajo de un umbral fijado en validación.
¿Qué error cuesta más?	Una etiqueta equivocada emitida con alta confianza, porque entra al registro como dato válido. Le sigue forzar a una de las cinco clases una flor que no pertenece a ninguna.
Dentro del alcance	Clasificación cerrada de cinco clases en fotos de aficionado; salida calibrada con opción de abstenerse y latencia medida en CPU.
Fuera del alcance	Otras especies, detección o segmentación, inferencias sobre toxicidad, comestibilidad o uso medicinal, y cualquier análisis de personas.

Unidad de observación. La entidad que se espera generalizar es el **fotógrafo y su escena**; cada imagen hereda de ellos cámara, jardín y a veces la misma planta, y un mismo autor de Flickr aporta hasta 63 fotos. Por eso la partición agrupa por autor (sección 4), como pide la regla de separar por entidad independiente antes de mezclar (Rodríguez Meléndez, 2026; Scikit-learn Developers, s. f.-b).

2. Origen, licencia, composición y limitaciones del dataset

tf_flowers proviene del archivo flower_photos.tgz que el equipo de TensorFlow publicó para sus tutoriales (TensorFlow Team, 2019); la descarga oficial se verificó con SHA-256 (4c54ace7…3e595d9c). Cada foto conserva una licencia CC-BY 2.0 y su atribución en LICENSE.txt, de modo que el repositorio no redistribuye imágenes: publica código, identificadores por partición y atribuciones. La composición es de 3 670 imágenes (margarita 633, diente de león 898, rosa 641, girasol 699, tulipán 799; razón máxima/mínima 1,42), con resolución mediana de 320 × 240 px y 1 531 autores. La hoja de datos completa sigue las siete secciones de Gebru et al. (2021) y está en docs/datasheet_tf_flowers.md.

Las limitaciones condicionan la validez externa. El criterio de selección de las fotos y su periodo son desconocidos para el equipo; las flores son sobre todo cultivadas y de estética fotográfica occidental, lejos de la flora del Caribe colombiano; no existe partición oficial; y el corpus de preentrenamiento de DINOv2 (LVD-142M) se construyó por recuperación a partir de conjuntos públicos, por lo que no se descarta solapamiento visual con estas fotos (Oquab et al., 2024). Esta última limitación hace que el desempeño en datos limpios deba leerse como cota optimista.

3. Auditoría inicial de calidad

La auditoría (src/flores/auditoria.py) calculó para cada imagen MD5 de bytes y de píxeles, hash perceptual de 64 bits, saturación, brillo, contraste, varianza del laplaciano y ruido de Immerkær (1996). La Tabla 2 resume los hallazgos y la decisión que cada uno produjo; ninguna imagen se modificó.

Tabla 2

Hallazgos de la auditoría y decisiones derivadas

Hallazgo	n	Decisión
Sin línea de licencia verificable	9	Excluidas (no se puede cumplir la atribución)
Misma foto en las carpetas de rosas y tulipanes	2	Excluidas por etiqueta contradictoria
Pares casi duplicados (pHash ≤ 6 bits)	22 pares	Agrupados; nunca cruzan particiones
Autores con fotos en más de una clase	282	El autor es la unidad de agrupamiento
Casi monocromas (saturación media < 0,08)	88	Se conservan; 49 son dientes de león: posible atajo de color, se analiza como subgrupo
Oscuras (brillo < 50) / sobreexpuestas (> 200)	149 / 32	Se conservan; subgrupos del análisis de errores
Borrosas (var. laplaciano < 50) / ruido alto (σ > 15)	21 / 135	Se conservan; motivan la prueba de robustez
Lado menor < 200 px	397	Se conservan; subgrupo de baja resolución

Nota. Umbrales declarados en el cuaderno. Las dos primeras filas se cuentan sobre las 3 670 imágenes; las demás, sobre las 3 659 que quedan tras las exclusiones.

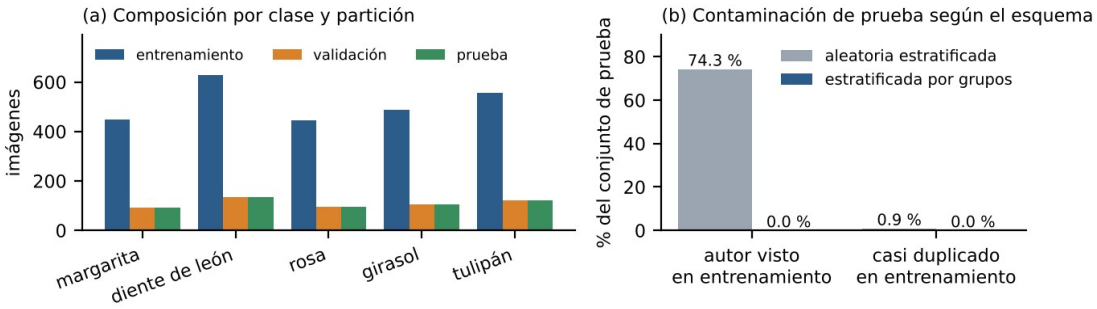
4. Esquema de particiones y control de fuga

Un grupo de fuga es la componente conexa del grafo que une imágenes con el mismo autor, los mismos píxeles o un pHash a seis bits o menos. Con los 1 531 grupos se aplicó StratifiedGroupKFold (20 pliegues, semilla 2026): tres pliegues para prueba, tres para validación y catorce para entrenamiento, lo que dio 2564 / 548 / 547 imágenes con la misma mezcla de clases (desviación ≤ 0,5 puntos). Todo componente que aprende de los datos (escalador, selección de C, umbral de abstención y, en la Actividad 2, temperatura de calibración) se ajusta solo con entrenamiento o validación (Scikit-learn Developers, s. f.-a). La validación elige hiperparámetros dentro de cada estudio; la CV agrupada compara configuraciones (Scikit-learn Developers, s. f.-b); la prueba se abre una sola vez por modelo finalista. Las cifras de robustez y abstención de E03 en prueba que se informan en la sección 7 son descriptivas: solo motivaron hipótesis, y en la Actividad 2 esos criterios se miden en los pliegues de la CV agrupada. Cinco pruebas automáticas verifican que ningún grupo, autor o par de píxeles idénticos cruce particiones y que se respeten proporciones y exclusiones; otras tres validan las métricas.

La Figura 1b muestra por qué la partición ingenua no sirve: con una división aleatoria estratificada, 74,3 % de las fotos de prueba tendrían un autor visto en entrenamiento y 5 tendrían su casi duplicado allí; con la partición agrupada ambas cifras son cero (Scikit-learn Developers, s. f.-a). La validación cruzada agrupada en cinco pliegues sobre entrenamiento y validación (sin tocar prueba) arrojó para E03 un macro-F1 de 0,961 ± 0,009, con pliegues entre 0,948 y 0,970. La prueba (0,987) quedó por encima de todos ellos, de modo que una sola partición sobrestima el desempeño; por eso la Actividad 2 seleccionará y comparará modelos con esta validación cruzada agrupada y reservará la prueba para el reporte final (Scikit-learn Developers, s. f.-b). Se esperan dos desplazamientos frente al uso real: de covariables (cámaras de celular, luz tropical, fondos escolares) y de etiqueta o alcance (flores ajenas a las cinco clases), dos de los tipos de desplazamiento que el docente pidió explicitar (Rodríguez Meléndez, 2026).

Figura 1

Composición de la partición agrupada (a) y contaminación de prueba según el esquema de partición (b)



5. Preprocesamiento

El preprocesamiento forma parte del modelo desplegado (Rodríguez Meléndez, 2026) y es el mismo en entrenamiento, evaluación e inferencia, para evitar el sesgo entre entrenamiento y servicio (Zinkevich, s. f., Regla 32). E01 reduce a 128 × 128

px y concatena un histograma HSV de 16 × 4 × 4 contenedores con HOG de nueve orientaciones (2 020 rasgos; Dalal y Triggs, 2005), estandarizados con media y varianza de entrenamiento. E02 usa 96 × 96 px escalado a [0, 1] y, solo en entrenamiento, la aumentación combinada que fue útil en la U2A4 (volteo horizontal, rotación ±36° y zoom ±20 %). E03 sigue el contrato del modelo fundacional: redimensión bicúbica a 256 px, recorte central de 224 px y normalización con la media y desviación de ImageNet (Oquab et al., 2024).

6. Métricas de éxito

La función de pérdida (entropía cruzada) no es la métrica de decisión, y esta se define antes de entrenar (Zinkevich, s. f., Regla 2). La métrica primaria es el **macro-F1**, porque pondera por igual las cinco clases ante un desbalance de 1,42 y no se infla con la clase mayoritaria; en multiclase de etiqueta única el micro-F1 coincide con la exactitud, que por eso queda como secundaria; la Tabla 4 reporta en su lugar la exactitud balanceada. El macro-F1 en prueba se reporta con un intervalo bootstrap del 95 % que remuestrea **autores**, coherente con la unidad de observación; E02 se resume con media ± DE de tres semillas y la validación cruzada con media ± DE de cinco pliegues. Las metas de la Tabla 3 se fijan antes de entrenar la arquitectura candidata.

Tabla 3

Métricas, justificación y criterio de éxito para la Actividad 2

Métrica	Por qué	E03 hoy	Criterio de éxito
Macro-F1 medio, CV agrupada k = 5 (métrica de desarrollo)	Clases con igual peso; autores no vistos (Scikit-learn Developers, s. f.-b)	0,961 ± 0,009	≥ 0,971 y DE ≤ 0,010
Macro-F1 en prueba (una sola vez)	Reporte final sin selección (Scikit-learn Developers, s. f.-a)	0,987	No inferior: ≥ 0,977
Macro-F1 con resolución a 1/4	Peor degradación medida (Hendrycks y Dietterich, 2019)	0,954	≥ 0,970
Recall mínimo por clase	Ninguna clase descuidada	0,968	Restricción: ≥ 0,95
ECE (15 contenedores)	La confianza debe significar algo (Guo et al., 2017)	0,009	Restricción: ≤ 0,02 tras escalado de temperatura
Cobertura con precisión ≥ 99 %	Error más costoso: confianza equivocada	96,0 %	≥ 98 % con precisión ≥ 99 %
Latencia P95 por imagen (CPU, 2 hilos)	Portátil escolar sin GPU	141 ms	Restricción: ≤ 200 ms

Nota. ECE según Guo et al. (2017). El umbral de abstención (0,90) se fijó en validación para lograr una precisión de 99 % en lo aceptado; en prueba acepta 96,0 % de las fotos con precisión de 99,8 %. en validación, la cobertura es 91,2 % y el ECE 0,023. Salvo la primera fila, "E03 hoy" se midió en prueba. Las restricciones impiden empeorar y no definen mejora. El margen de 0,010 equivale a una DE entre pliegues de E03, la menor diferencia que el diseño distingue del ruido de partición. La mejora se declara con diferencias pareadas en los mismos cinco pliegues y se confirma una sola vez en prueba con McNemar exacto (Dietterich, 1998).

7. Línea base implementada y primeros resultados

La escalera de líneas base responde una pregunta por peldaño: E00 (clase mayoritaria) fija el piso trivial; E01 pregunta si bastan descriptores de forma y color; E02 pregunta si una CNN pequeña sin preentrenamiento compensa su costo; E03 pregunta cuánto aporta una representación fundacional congelada sin ajuste fino (Oquab et al., 2024). Las cuatro comparten partición, métrica primaria y prueba, y cada una hereda de la clase abstracta BaseExperimento; los parámetros, métricas y artefactos quedan registrados en MLflow (MLflow Project, s. f.; Tabla 4).

Tabla 4

Resultados de las líneas base en la partición de prueba agrupada

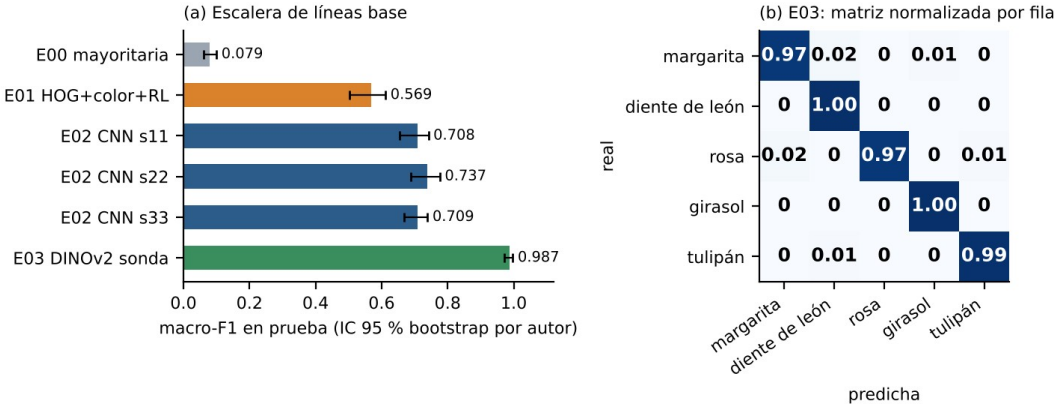
Run	Modelo	Macro-F1 (IC 95 %)	Exact. bal.	ECE	Parám. entren.	Entren.	P95 ms
E00	Clase mayoritaria	0,079 (0,062 a 0,100)	0,200	0,754	0	0 s	n. a.
E01	HOG + HSV + regresión logística	0,569 (0,503 a 0,612)	0,569	0,120	10 105	2,7 s	10,1
E02	CNN conv 16-32-64 + densa 128, 96 px, 3 semillas	0,718 ± 0,017	0,721	0,062	1 204 005	5,4 min/semilla	3,4
E03	DINOv2 ViT-S/14 congelado + RL	0,987 (0,971 a 0,997)	0,986	0,009	1 925	0,4 s	141

Nota. CPU de 2 hilos. Entren.: ajuste final con el C elegido (E01, E03) o 30 épocas con evaluación por época en validación (E02, media de semillas); aparte, la extracción de rasgos tarda 17 s en E01 y 312 s en E03 (3 659 embeddings). P95 de E02: media de semillas. E02: media ± DE de las semillas 11, 22 y 33; tres convoluciones 3 × 3 (16, 32 y 64 filtros) con max-pooling, densa de 128 y salida de 5; mejor época según pérdida de validación. E03: 21,6 M de parámetros congelados. Parámetros entrenables de E01 = 2 020 × 5 + 5. Macro-F1 de E03 en validación: 0,950.

La comparación pareada sobre las mismas 547 fotos favorece a E03 frente a E01 y frente a E02 (McNemar exacto, $p < 10^{-36}$ frente a cada semilla de E02 y $p < 10^{-64}$ frente a E01; Dietterich, 1998). Dos controles respaldan la validez: con etiquetas de entrenamiento permutadas la sonda cae a un macro-F1 de 0,211 en validación, señal de que la tubería no filtra información, y la corrida independiente del repositorio reproduce las cifras de la exploración inicial. E03 comete solo 7 errores en prueba, tres en margaritas (dos tomadas por diente de león y una por girasol), tres en rosas (dos por margarita y una por tulipán) y un tulipán tomado por diente de león. Ante degradaciones de captura de severidad media (Hendrycks y Dietterich, 2019) la representación congelada resiste más de lo esperado: el macro-F1 es 0,977 con desenfoque gaussiano (radio 2), 0,988 con JPEG de calidad 20 y 0,987 con subexposición al 50 % (idéntico al de las fotos limpias). La excepción es la reducción a la cuarta parte de la resolución (0,954, pérdida relativa de 3,3 %), pertinente porque 397 fotos del conjunto ya tienen menos de 200 px de lado.

Figura 2

Escalera de líneas base con IC 95 % por autor (a) y matriz de confusión normalizada de E03 (b)



Dos lecturas guían la fase siguiente. El modelo clásico rinde mal (0,57), condición que el docente fijó para justificar el paso a redes profundas (Rodríguez Meléndez, 2026), y la CNN desde cero mejora sin acercarse a la representación fundacional pese a un costo de entrenamiento mayor. Como la prueba está casi saturada, la mejora relevante está en subir el promedio de la CV agrupada, en sostener el desempeño con fotos de baja resolución y en abstenerse cuando corresponde (Zinkevich, s. f., Regla 25).

8. Riesgos de sesgo, privacidad, seguridad y uso indebido

Los riesgos se organizaron con las funciones MAP, MEASURE y MANAGE del marco de gestión de riesgos del National Institute of Standards and Technology (NIST, 2023). Como los usuarios previstos incluyen estudiantes menores de edad, la privacidad se trata como riesgo activo (NIST, 2023); la Tabla 5 resume riesgos y mitigaciones.

Tabla 5

Matriz de riesgos y mitigación

Tipo	Riesgo	Mitigación y evidencia
Sesgo estadístico	Flores cultivadas, estética occidental y desbalance 1,42; 49 de las 88 fotos casi monocromas son dientes de león (atajo de color o fondo).	Macro-F1, recall por clase, análisis por subgrupos (monocroma, oscura, baja resolución; Mitchell et al., 2019) y mapas de atención en la Actividad 2.
Sesgo por autor	Estilo del fotógrafo aprendido como señal de clase.	Partición e IC agrupados por autor; CV agrupada (Scikit-learn Developers, s. f.-b).
Validez externa	Posible solapamiento de LVD-142M con fotos de Flickr (Oquab et al., 2024); flora tropical no representada.	Cifras limpias leídas como cota optimista; prueba de robustez; conjunto de campo opcional con fotos propias.
Privacidad	Personas o viviendas incidentales en fotos; nombres de usuario de Flickr en las atribuciones.	El autor se usa solo para agrupar y los nombres de Flickr solo cumplen la atribución CC-BY; fotos de campo únicamente con consentimiento de acudientes (Ley 1581 de 2012), sin rostros ni EXIF o GPS.
Seguridad	Pesos y dependencias de terceros alterados; ejemplos adversarios.	Pesos safetensors de timm con versión fijada, requirements fijados, SHA-256 de datos, secretos en .gitignore; robustez adversaria fuera de alcance y declarada (NIST, 2023).
Uso indebido	Usar la salida para decidir sobre toxicidad, comestibilidad o especies ajenas; automatizar el registro sin revisión.	Abstención calibrada, advertencia de uso en la ficha del modelo (Mitchell et al., 2019) y revisión docente de los registros.

9. Arquitectura candidata y diseño experimental de la Actividad 2

La candidata es **DINOv2 ViT-S/14** (Oquab et al., 2024), con 21,6 M de parámetros y licencia Apache 2.0, adaptado con LP-FT: se parte de la cabeza lineal de E03 y luego se ajustan los últimos bloques del transformador con una tasa de aprendizaje baja. Kumar et al. (2022) mostraron que esta secuencia deforma menos las representaciones preentrenadas que el ajuste fino directo y rinde mejor fuera de distribución, que es donde se juegan los autores no vistos y las fotos de baja resolución. Como alternativa de eficiencia se evalúa LoRA de rango 8 en las proyecciones de atención (Hu et al., 2022), que se fusiona con los pesos y no añade latencia. La aumentación de entrenamiento usa familias distintas de las perturbaciones de prueba (recorte aleatorio, color, volteo y RandAugment), para no entrenar contra el examen (Hendrycks y Dietterich, 2019). Después del ajuste se aplica calibración post hoc por escalado de temperatura en validación (Guo et al., 2017).

Tabla 6

Experimentos controlados previstos (una variable científica por estudio)

Run	Pregunta	Variable científica	Ajuste en validación
E04	¿Ajustar los últimos 2 bloques mejora la robustez frente a E03?	LP-FT, k = 2 (Kumar et al., 2022)	LR {1e-5, 3e-5, 1e-4}, decaimiento de pesos
E05	¿Ajustar más bloques ayuda o sobreajusta?	LP-FT, k = 4	Igual que E04
E06	¿LoRA iguala a LP-FT con menos parámetros entrenables?	LoRA r = 8 (Hu et al., 2022)	LR, α
E07	¿La aumentación fotométrica y geométrica aporta robustez?	Con o sin aumentación	Igual que la mejor de E04 a E06
E08	¿La calibración reduce la confianza equivocada?	Temperatura T (Guo et al., 2017)	T por NLL en validación

Nota. Fijos: partición, 224 px, lote de 32, preprocesamiento y métricas. E04 a E06 se entrenan sin aumentación; E07 la añade a la mejor de ellas. Cada valor de la tasa de aprendizaje se prueba con una semilla en validación y la ganadora de cada estudio se evalúa en los cinco pliegues de la CV agrupada; las semillas 11, 22 y 33 se reservan para la finalista. Todo run recibe el mismo presupuesto de 30 minutos de GPU T4 en lugar de un número fijo de épocas, porque los modelos difieren en capacidad (Google Developers, s. f.; Rodríguez Meléndez, 2026); el total ronda 16 h de GPU, repartidas entre las dos cuentas de Colab del equipo. Si ninguna variante supera la Tabla 3, se conserva E03, la opción más barata.

10. Cronograma, roles y criterios de reproducibilidad

Tabla 7

Cronograma hasta el cierre de la Unidad 4 y responsables

Fecha	Hito	Responsable
6 a 18 oct	Formulación, auditoría, partición, líneas base E00 a E03 y este plan (A1)	Ambos; LSM lidera datos y escritura
19 a 20 oct	E04 a E06 en GPU (Colab T4) con registro en MLflow (MLflow Project, s. f.); curvas y mejores checkpoints	JJSC; revisión de LSM
21 oct	E07 y E08, prueba de robustez, umbral de abstención y calibración	JJSC (código) y LSM (estadística)
22 oct	Análisis de errores por clase y subgrupo con mapas de atención; ficha del modelo final (Mitchell et al., 2019; borrador en docs/)	LSM; revisión de JJSC
23 oct	Reporte técnico de la A2 (≤ 6 p.) y etiqueta v0.2 del repositorio	Ambos
24 a 25 oct	Informe final (8 a 12 p.), presentación (8 a 12 diapositivas), README verificado; entrega A2 y A3	Ambos; sustentan los dos

Roles. Leonar Socarrás Molina (LSM) dirige la formulación, la hoja de datos, la partición, el análisis estadístico y la redacción. John Jairo Serrano Cifuentes (JJSC) dirige la ingeniería del pipeline de ajuste fino, el registro en MLflow y la medición de eficiencia. Cada uno evalúa en prueba los modelos que no ajustó, como recomienda NIST (2023, MEASURE 1.3).

Reproducibilidad. (1) Datos: URL oficial, SHA-256, hoja de datos (Gebru et al., 2021), exclusiones y partición versionadas con su hash registrado en cada run. (2) Código: repositorio público con configs/, src/, tests/, notebooks/, outputs/, docs/, README y requirements con versiones exactas. (3) Configuración: una YAML por run, sin hiperparámetros dispersos en el código (Rodríguez Meléndez, 2026). (4) Aleatoriedad: semillas enteras fijas (partición 2026; CNN 11, 22, 33), como recomienda Scikit-learn Developers (s. f.-a), y algoritmos deterministas en PyTorch. (5) Trazabilidad: MLflow con parámetros, métricas por época, artefactos y el mejor checkpoint según validación (MLflow Project, s. f.). (6) Verificación: ocho pruebas automáticas y una segunda corrida que reproduce las cifras. El cuaderno 01_plan_experimental_lineas_base.ipynb ejecuta y comunica toda esta evidencia (https://github.com/leonarsomo/flores-proyecto-integrador).

Referencias

Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. En *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)* (Vol. 1, pp. 886-893). IEEE. https://doi.org/10.1109/CVPR.2005.177

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation, 10*(7), 1895-1923. https://doi.org/10.1162/089976698300017197

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86-92. https://doi.org/10.1145/3458723

Google Developers. (s. f.). *A scientific approach to improving model performance*. En *Deep learning tuning playbook*. https://developers.google.com/machine-learning/guides/deep-learning-tuning-playbook/scientific

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. En *Proceedings of the 34th International Conference on Machine Learning* (Vol. 70, pp. 1321-1330). PMLR. https://proceedings.mlr.press/v70/guo17a.html

Hendrycks, D., & Dietterich, T. (2019). Benchmarking neural network robustness to common corruptions and perturbations. En *International Conference on Learning Representations*. https://arxiv.org/abs/1903.12261

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. En *International Conference on Learning Representations*. https://arxiv.org/abs/2106.09685

Immerkær, J. (1996). Fast noise variance estimation. *Computer Vision and Image Understanding, 64*(2), 300-302. https://doi.org/10.1006/cviu.1996.0060

Kumar, A., Raghunathan, A., Jones, R., Ma, T., & Liang, P. (2022). Fine-tuning can distort pretrained features and underperform out-of-distribution. En *International Conference on Learning Representations*. https://arxiv.org/abs/2202.10054

Ley 1581 de 2012. Por la cual se dictan disposiciones generales para la protección de datos personales. 17 de octubre de 2012. *Diario Oficial* No. 48.587.

MLflow Project. (s. f.). *MLflow Tracking*. MLflow Documentation. https://mlflow.org/docs/latest/ml/tracking/

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220-229). ACM. https://doi.org/10.1145/3287560.3287596

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)* (NIST AI 100-1). U.S. Department of Commerce. https://doi.org/10.6028/NIST.AI.100-1

Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., . . . Bojanowski, P. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. https://arxiv.org/abs/2304.07193

Rodríguez Meléndez, O. A. (2026). *Diseño experimental e ingeniería de proyectos de ML* [Diapositivas y sesión sincrónica del 13 de octubre]. Técnicas Avanzadas de Modelado en IA, Universidad de La Sabana.

Rodríguez Meléndez, O. A., & Mojica Macías, J. P. (2026). *Proyecto integrador de modelado avanzado en ML y DL* [Cartilla interactiva de la Unidad 4]. Técnicas Avanzadas de Modelado en IA, Universidad de La Sabana.

Scikit-learn Developers. (s. f.-a). *Common pitfalls and recommended practices*. https://scikit-learn.org/stable/common_pitfalls.html

Scikit-learn Developers. (s. f.-b). *Cross-validation: Evaluating estimator performance*. https://scikit-learn.org/stable/modules/cross_validation.html

TensorFlow Team. (2019). *Flowers* [Conjunto de datos]. TensorFlow Datasets. https://www.tensorflow.org/datasets/catalog/tf_flowers

Zinkevich, M. (s. f.). *Rules of machine learning: Best practices for ML engineering*. Google for Developers. https://developers.google.com/machine-learning/guides/rules-of-ml

Declaración de uso de IA. El equipo usó Claude (Anthropic) como asistente para programar, revisar fuentes y redactar borradores; las decisiones, la verificación de cifras contra el repositorio y la versión final son responsabilidad de los autores.